DAILY BRIEFING

AI 资讯日报

2026年3月28日 星期六

74	10	6	7.0	74
资讯条目	分类覆盖	信息来源	平均评分	深度解读

⭐ 今日推荐 TOP 3

🥇 AI使用技巧 8.5

Ask HN: Is consumer AI boxes a viable idea?

HN讨论：消费级AI硬件盒子是不是个好生意?

🥈 AI使用技巧 8.5

Show HN: I block LLM hallucinations with a cognitive math framework(re!Think it)

用认知数学框架阻止LLM幻觉——一个反直觉的Prompt工程方法

🥉 AI使用技巧 8.5

Show HN: LLM-Gateway — Zero-Trust LLM Gateway

单Go二进制的零信任LLM网关，一个YAML配多个后端

受众分布

小白	28	28(37%)
新手	0	0(0%)
进阶	35	35(47%)
高级	11	11(14%)

目录

🤖 AI智能体 (22) ⚡ SKILL介绍 (11) 🧠 AI模型 (7) 📦 开源项目 (3) 📱 AI应用 (7)
☁️ AI服务 (3) 💰 商业模式 (6) 🚀 创业项目 (2) 💡 AI使用技巧 (10) 📚 小教程 (3)

🤖 AI智能体 22 条

zeroclaw-labs/zeroclaw

进阶 6.5

GitHub

> 全自主AI助手基础设施，Rust写的，跨平台部署，近3万星

Fast, small, and fully autonomous AI personal assistant infrastructure, ANY OS, ANY PLATFORM — deploy anywhere, swap anything 🦀 (stars: 28,978) [Rust] 🦀 ZeroClaw — Personal AI Assistant Zero overhead. Zero compromise. 100% Rust. 100% Agnostic. ⚡ Runs on $10 hardware with

为什么你该关心

如果你在找一个可以在任何设备上跑的AI助手框架，ZeroClaw用Rust实现了极致性能和跨平台能力。对于想脱离云服务自建AI的团队，这是目前最成熟的选择之一。

你现在能做什么

1. 克隆仓库试跑：git clone + cargo build
2. 对比OpenClaw看架构差异

zeroclaw align center strong labs

opencmit/alphora

进阶 6.5

GitHub

> 生产级可组合AI Agent框架，Python生态，开箱即用

Alphora是一个面向生产环境设计的可组合AI Agent框架。与LangChain等原型友好框架不同，Alphora从一开始就考虑了生产环境的需求：可靠的错误处理、组件热替换、状态持久化和完整的可观测性。框架采用组合式架构，开发者可以像搭积木一样选择和组合不同的Agent组件——记忆模块、工具集、规划器和执行器。344星虽不多，但面向生产级Agent的定位填补了目前框架生态中的重要空白。

为什么你该关心

做Agent应用最头疼的是从demo到生产的鸿沟。Alphora直接面向生产环境设计，组合式架构让你像搭积木一样拼Agent。适合已经玩过LangChain想要更稳定方案的团队。

你现在能做什么

1. pip install alphora，跑官方example
2. 对比LangGraph/CrewAI看哪个更适合你的场景

img src alt https shields

CortexReach/memory-lancedb-pro

进阶 6.5

GitHub

> 给OpenClaw加上向量+BM25混合检索的长期记忆插件

Enhanced LanceDB memory plugin for OpenClaw — Hybrid Retrieval (Vector + BM25), Cross-Encoder Rerank, Multi-Scope Isolation, Management CLI (stars: 3,618) [TypeScript] # 🧠 memory-lancedb-pro · 🦞 OpenClaw Plugin **AI Memory Assistant for OpenClaw Agents** *Give your AI agent a brain that actually remembers — across sessions, across agents, across time.* A LanceDB-backed OpenClaw memory plugin...

为什么你该关心

AI Agent最大的痛点之一就是记忆。这个插件用LanceDB实现了向量+全文混合检索+Cross-Encoder重排序，还支持多作用域隔离。如果你在用OpenClaw但觉得记忆不够智能，这是直接的升级方案。

你现在能做什么

1. npm install memory-lancedb-pro
2. 配置到你的OpenClaw实例中测试检索效果

OpenClaw memory openclaw Plugin https

更多（19）

zilliztech/memsearch

进阶 6.5

Markdown优先的AI Agent记忆系统，灵感来自OpenClaw

InternScience/MLEvolve

高级 6.5

自动化ML算法设计与优化系统，用进化搜索+经验记忆驱动

ComposioHQ/agent-orchestrator

高级 6.5

Composio出品的并行编码Agent调度器，5500星，

crshdn/mission-control

高级 6.5

全球首个自主产品引擎：AI Agent自动调研市场、生成功能、提交PR

Lisovate/agent-ws

进阶 6.5

CLI AI Agent的WebSocket桥接器，

builderz-labs/mission-control

进阶 6.5

自托管的多Agent调度平台，统一看板管理任务、工作流和成本

nullclaw/nullclaw

高级 6.3

用Zig重写的极速AI助手基础设施，6800+星，比Rust版更极致

memovai/mimiclaw

高级 6.3

5美元芯片上跑OpenClaw，无需操作系统，纯硬件Agent

open-gitagent/gitagent 进阶 6.3
框架无关、Git原生的AI Agent定义标准

Intent-Lab/VisionClaw 小白 6.3
Meta智能眼镜的实时AI助手：语音+视觉+Agent行动，

vercel-labs/agent-browser 进阶 5.4
Vercel出品的AI Agent浏览器自动化CLI，Rust实现，2.5万星

volcengine/OpenViking 进阶 5.4
火山引擎开源的AI Agent专用上下文数据库

snarktank/ralph 进阶 5.4
Ralph：自主AI Agent循环执行PRD直到所有需求完成，1.4万星

agent-topia/evolving_personality 高级 5.4
基于荣格理论的LLM Agent动态MBTI人格模拟框架

baidu-baige/LoongFlow 高级 5.4
百度百舸出品的思考+学习Agent框架，目标是专家级AI Agent

aiming-lab/SimpleMem 进阶 5.4
LLM Agent的高效终身记忆系统，3200+星

benjitaylor/agentation 进阶 5.4
Agent的可视化反馈工具——让你看到Agent在想什么，3100+星

michaelshimeles/ralphy 高级 5.4
一个脚本同时跑Claude Code/Codex/OpenCode/Cursor

softaworks/agent-toolkit 小白 5.4
Softaworks Agent Toolkit

⚡ SKILL介绍 11 条

Show HN: Bottrace — headless CLI debugger for Python, built for LLM agents

进阶 8.3

HN-LLM

Bottrace——专为LLM Agent设计的Python无头CLI调试器

Article URL: https://github.com/devinvenable/bottrace Comments URL: https://news.ycombinator.com/item?id=47543043 Points: 3 # Comments: 0。

为什么你该关心

调试AI Agent比调试普通程序难得多——执行路径不确定、中间状态复杂。Bottrace专门为此设计，无头模式意味着可以集成到CI/CD中自动调试Agent故障。对做Agent开发的Python团队来说是生产力工具。

你现在能做什么

1. pip install bottrace，在你的Agent项目中试用
2. 集成到CI流程中自动检测Agent回归

URL https com Comments Show

Toolcast — Turn any API into an AI agent tool with one command

小白 8.3

HN-Agent

Toolcast——一条命令把任何API变成AI Agent可用的工具

Article URL: https://github.com/Djsand/toolcast Comments URL: https://news.ycombinator.com/item?id=47545895 Points: 3 # Comments: 0。

为什么你该关心

Agent能力的上限取决于它能调用多少工具。Toolcast自动把任意REST API转换成Agent工具格式，省去了手写工具定义的繁琐工作。对需要快速扩展Agent工具库的团队来说，效率提升是数量级的。

你现在能做什么

1. 对你最常用的API运行toolcast转换
2. 测试生成的工具定义在Agent中的实际效果

URL https com Comments Toolcast

nidhinjs/prompt-master

小白 7.5

GitHub

> 一个帮你写Prompt的Claude Skill，零浪费Token，

A Claude skill that writes the accurate prompts for any AI tool. Zero tokens or credits wasted. Full context and memory retention (stars: 2,473) A Claude skill that writes the accurate prompts for any AI tool. Zero tokens or credits wasted. Full context and memory retention. No re-prompting your way to an answer you should have gotten on attempt one. **Works with:** Claude, ChatGPT, Gemini, o...

为什么你该关心

写Prompt是门手艺活，这个Skill把Prompt工程自动化了。2400+星，支持多平台AI工具的Prompt生成。对于频繁需要写高质量Prompt的用户，能节省大量试错时间。

你现在能做什么

1. 安装到Claude Code中试用
2. 对比你手写的Prompt看质量差异

Claude any AI tool skill

更多（8）

onvoyage-ai/gtm-engineer-skills

小白 7.5

Claude Code技能：16项检查+6项优化，提升网站的AI搜索引擎可见度

matt1398/claude-devtools

进阶 6.5

Claude Code的浏览器式DevTools

Donchitos/Claude-Code-Game-Studios

进阶 6.5

48个AI Agent + 36个工作流Skill，

coreyhaines31/marketingskills

小白 5.4

Claude Code的营销技能包——CRO/SEO/文案/增长工程，1.7万星

heilcheng/awesome-agent-skills

小白 5.4

AI编码Agent技能/工具/教程精选清单，

mverab/eGEOagents

小白 5.4

AI Agent的GEO优化技能

langfuse/skills

进阶 5.4

Langfuse官方Agent技能集——为开源LLM工程平台增加Agent能力

fengshao1227/ccg-workflow

进阶 5.4

CCG工作流——结构化的AI Agent任务编排工具

🧠 AI模型 7 条

alvinunreal/awesome-opensource-ai

小白 8.5

GitHub

> 精选的真正开源AI项目清单——模型、工具、基础设施一网打尽

Awesome Open Source AI是一份精心策划的真正开源AI项目清单，覆盖模型、工具和基础设施三大类。严格筛选标准——只收录许可证真正允许自由使用、修改和分发的项目，排除那些名为开源实为受限的项目。1423星反映了社区对「真正开源」筛选标准的认可。对于在开源和商业AI方案之间做技术选型的团队，这份清单是重要的参考索引，可以避免踩到许可证陷阱。

为什么你该关心

开源AI项目鱼龙混杂，很多号称开源其实有限制。这份清单只收录真正开源的项目，1400+星说明社区认可其筛选标准。找开源替代方案时的权威参考。

你现在能做什么

1. 收藏仓库作为开源AI索引
2. 检查你目前用的AI工具是否有更好的开源替代

AI https awesome img Awesome

LLM Persuasion Benchmark: Multi-Turn Persuasion Between Models

高级 8.3

HN-LLM

> LLM说服力基准测试——衡量模型在多轮对话中说服人类的能力

Article URL: https://github.com/lechmazur/persuasion Comments URL: https://news.ycombinator.com/item?id=47545308 Points: 8 # Comments: 0。

为什么你该关心

AI的说服能力是双刃剑——理解它才能防范它。这个基准测试系统评估不同LLM在多轮对话中的说服力。对做AI安全、对话系统设计或需要评估模型影响力的研究者非常有价值。

你现在能做什么

1. 跑benchmark对比主流模型的说服力得分
2. 思考说服力评估在你的应用中的意义

Persuasion URL https com Comments

omnimind-ai/OmniInfer

进阶 7.5

GitHub

跨平台LLM推理框架，专为边缘设备高效部署设计

Cross-platform LLM inference framework for efficient edge deployment (stars: 269) [Python] # OmniInfer Easy, fast, and private LLM & VLM inference for every device | Documentation | Architecture | Supported Models | ## About OmniInfer is a high-performance, cross-platform inference engine for running Large Language Models (LLM) and Vision-Language Models (VLM) locally. It abstracts awa...

为什么你该关心

在手机、嵌入式设备上跑LLM的需求越来越大。OmniInfer提供了统一的跨平台推理接口，支持多种后端。对做端侧AI部署的团队是基础设施级工具。

你现在能做什么

1. pip install omniinfer，在你的设备上跑benchmark
2. 对比llama.cpp和MLC-LLM看推理性能

inference OmniInfer LLM Models platform

更多（4）

EncyclopediaWorld/howaiworks 小白 7.5

用交互式可视化解释AI工作原理的教育项目

larsderidder/context-lens 进阶 6.5

上下文镜头——帮你理解和管理LLM的上下文窗口使用情况

geo-team-red/geo-optimizer 进阶 6.5

地理空间优化器——用AI解决物流、选址等空间优化问题

cuongpt083/smart-pole-skill 高级 6.3

智能电线杆Skill——用AI监控和管理城市基础设施

📦 开源项目 3 条

CrewForm — Open-source multi-agent AI orchestration platform

进阶 8.3

HN-AI

CrewForm——开源的多Agent AI编排平台

CrewForm是一个开源的多Agent AI编排平台，采用MIT许可。允许开发者定义、调度和监控多个AI Agent的协作工作流。与CrewAI等框架类似但更强调开源社区驱动和可扩展性。在多Agent编排赛道日益拥挤的今天，CrewForm的差异化在于纯开源路线和平台化定位——不只是一个框架，而是一个完整的编排平台，包含任务管理、Agent监控和工作流可视化。

为什么你该关心

又一个多Agent编排方案，与CrewAI、agent-orchestrator等竞争。开源+MIT许可意味着可以自由商用。多Agent编排赛道越来越拥挤，但也说明市场需求真实存在。

你现在能做什么

1. 对比CrewAI和agent-orchestrator的差异
2. 评估是否需要切换编排方案

CrewForm URL https com Comments

Memory Crystal — persistent memory for AI agents (MIT)

进阶 8.3

HN-AI

Memory Crystal——AI Agent的持久化记忆方案，MIT开源

Memory Crystal是一个为AI Agent设计的持久化记忆系统，MIT开源许可。核心理念是确保Agent的记忆在任何情况下（重启、升级、迁移）都不会丢失。采用结构化存储+向量索引的混合架构，支持记忆的版本控制和回溯。在Agent记忆赛道（SimpleMem、MemSearch、memory-lancedb-pro等）中，Memory Crystal更强调「持久性」和「抗灾性」——这也是生产环境中最被忽视的需求。

为什么你该关心

Agent记忆赛道的又一个选手。Memory Crystal强调的是「持久化」——确保Agent的记忆不会因为重启或升级而丢失。MIT许可对商用友好。Agent记忆正在成为独立的技术品类。

你现在能做什么

1. 对比SimpleMem和MemSearch评估适用场景
2. 在你的Agent中测试记忆持久化效果

URL https com memorycrystal Comments

OpenCode-LLM-proxy — use any OpenCode model via OpenAI/Anthropic/Gemini API

进阶 8.3

HN-LLM

> OpenCode LLM代理——一个YAML把OpenAI/Anthropic/

OpenCode LLM Proxy是一个轻量级的LLM代理服务，让你通过统一的OpenAI兼容API调用多个LLM厂商的模型（OpenAI、Anthropic、Gemini等）。一个YAML配置文件即可切换后端模型，无需修改应用代码。对于需要多模型对比测试、模型故障转移或成本优化（不同任务用不同价位模型）的团队来说，是必备的基础设施中间件。Go语言实现，部署简单。

为什么你该关心

多模型统一接入的需求持续增长。OpenCode LLM Proxy让你用一套API调用多个LLM厂商的模型，YAML配置即可切换。对需要多模型对比或故障转移的场景非常实用。

你现在能做什么

1. 部署代理，配置你常用的LLM后端
2. 测试模型切换的延迟和兼容性

OpenCode proxy URL https com

📱 AI应用 7 条

Apple's AI Playlist Playground is bad at music

小白 8.4

The Verge AI

> Apple Music的AI歌单功能翻车了——推荐结果牛头不对马嘴

Apple Music: "What do you want to hear?" Me: "Atmospheric instrumental black metal to write to." Apple Music: "Here's three metal songs with vocals, a field recording, an ambient electronic track, and a piece of doom jazz." I am skeptical of AI's ability to serve up the music I want to begin with, but even [...]

为什么你该关心

Apple的AI Playlist Playground表现很差，用户要金属乐给了流行，要古典给了电子。这说明音乐理解仍然是AI的弱项。对做音乐推荐或AI产品的团队来说，是一个很好的反面教材。

你现在能做什么

1. 体验Apple Music的AI歌单功能感受痛点
2. 如果你在做推荐系统，思考如何避免类似问题

Apple AI music Music want

Meta gets ready to launch two new Ray-Ban AI glasses

小白 8.4

The Verge AI

Meta即将发布两款新Ray-Ban AI眼镜，AI可穿戴竞争加速

This is Lowpass by Janko Roettgers, a newsletter on the ever-evolving intersection of tech and entertainment, syndicated just for The Verge subscribers once a week. Meta and its AI glasses hardware partner EssilorLuxottica are getting ready to launch the next generation of their Ray-Ban AI glasses. That's according to a series of FCC filings for [...]

为什么你该关心

Meta在AI眼镜上押注越来越重，新款硬件意味着更强的视觉理解和更长的续航。可穿戴AI正在从概念走向日用品。对于关注AI硬件趋势的从业者，这是必须跟踪的赛道。

你现在能做什么

1. 关注发售时间和定价
2. 评估AI眼镜在你的应用场景中的可能性

AI glasses Meta ready launch

qingchencloud/clawpanel

进阶 7.5

GitHub

开源的Claw管理面板，一键管理多个Claw实例

ClawPanel是一个开源的AI Claw实例管理面板。提供Web UI来统一管理多个AI Claw实例的运行状态、配置参数和日志输出。适合同时运行多个AI助手实例的团队或个人，可以在一个Dashboard中查看所有实例的健康状态、资源消耗和任务进度。Docker一键部署，轻量级设计不会占用太多额外资源。自建AI基础设施的运维必备工具。

为什么你该关心

如果你同时跑多个AI Claw实例，需要一个统一的管理面板。轻量级Web UI，适合自建AI基础设施的团队。

你现在能做什么

1. Docker部署，绑定你的Claw实例

AI qingchencloud clawpanel OpenClaw Visual

更多（4）

Austin-AS/AI_Emotional_Mirror 小白 5.4

AI情绪镜——输入文字就能分析情绪并给出温和的回应

ZhuLinsen/daily_stock_analysis 进阶 5.4

LLM驱动的A/H/美股智能分析器，多数据源+实时新闻+决策仪表盘，

saturndec/waoowaoo 进阶 5.4

工业级全流程AI影视生产平台——从短片到长片的可控AI视频制作

entireio/cli 小白 5.4

Entire.io CLI——命令行界面的AI助手客户端

☁️ AI服务 3 条

Google is making it easier to import another AI's memory into Gemini 小白 8.4

The Verge AI

> Google Gemini支持从其他AI导入记忆和聊天历史了

After Anthropic updated its tool for copying another AI's memory into Claude earlier this month, Google Gemini is rolling out new "Import Memory" and "Import Chat History" features on desktop that can help users quickly copy over everything their current AI already knows about them. To use the "Import Memory" tool, users copy and paste [...]

为什么你该关心

AI记忆的可迁移性成为竞争焦点——Anthropic先动，Google紧跟。用户不再被锁在一个AI平台上。这意味着AI助手的竞争将从「谁更聪明」转向「谁更懂你」。

你现在能做什么

1. 试试把Claude的记忆导入Gemini
2. 思考AI记忆可迁移对你的AI产品策略意味着什么

AI Import Google another memory

Apple will reportedly allow other AI chatbots to plug into Siri

小白 8.4

The Verge AI

> iOS 27将允许第三方AI聊天机器人接入Siri

Apple's iOS 27 update will allow users to choose the AI chatbot they want to link with Siri. That's according to a report from Bloomberg's Mark Gurman, who says third-party chatbots downloaded from the App Store, like Google's Gemini or Anthropic's Claude, will be able to fetch replies for Siri – similar to how the [...]

为什么你该关心

Apple终于开放了Siri的AI接入——用户可以选择ChatGPT、Claude等替代默认AI。这是AI分发渠道的重大变化，对所有AI公司来说都是新的流量入口。

你现在能做什么

1. 关注iOS 27 beta的AI接入API文档
2. 评估你的AI产品是否应该接入Siri

will Siri Apple allow AI

Google's 'live' AI search assistant can handle conversations in dozens more languages

小白 8.4

The Verge AI

> Google搜索的实时AI助手扩展到200+国家，支持更多语言

Google is expanding access to Search Live, a feature that lets you search for information using your voice and camera. The AI search assistant is now available in more than 200 countries and territories, as well as dozens of languages, according to an announcement on Thursday. Search Live rolled out broadly in the US last [...]

为什么你该关心

Google Search Live让你用语音和摄像头搜索信息，现在覆盖全球200+国家。AI搜索正在从文字输入走向多模态交互，传统SEO策略需要同步升级。

你现在能做什么

1. 体验Google Search Live的语音搜索
2. 评估你的内容是否对语音搜索友好

&# search Google 8217 AI

💰 商业模式 6 条

David Sacks Is No Longer the White House AI and Crypto Czar

小白 8.4

HN-AI

白宫AI与加密货币沙皇David Sacks离任

白宫AI与加密货币政策沙皇David Sacks正式离任。Sacks在任期间推动了美国AI监管框架和加密货币政策方向，包括对开源AI模型的态度、AI安全标准制定以及加密货币合规框架。他的离任可能导致美国AI政策出现方向调整。对在美国市场有AI业务的公司来说，继任者的政策倾向将直接影响模型发布、数据合规和市场准入等关键问题。需要持续关注白宫后续人事任命和政策风向。

为什么你该关心

美国AI政策的关键人物变动。Sacks离任可能影响美国对AI监管的走向，包括开源AI、数据隐私等政策。对在美国市场有业务的AI公司，这是需要关注的信号。

你现在能做什么

1. 关注继任者人选和政策方向变化

URL https com Comments David

The latest in data centers, AI, and energy

小白 8.4

The Verge AI

AI数据中心的能耗问题正在成为全行业的政治和商业焦点

Massive new data centers are the physical foundation for tech companies' hopes and dreams for AI. But the rush to expand warehouses full of energy-hungry servers has also kicked up fights across the world over their impact on power grids, utility bills, nearby communities, and the environment. From audacious plans to launch data centers into [...]

为什么你该关心

数据中心是AI的物理根基，但能耗争议正在升级。从电网负担到碳排放，AI基础设施面临越来越多的社会和政治压力。对于做AI基础设施或需要大量算力的团队，能源成本和合规将是越来越重要的变量。

你现在能做什么

1. 评估你的AI工作负载的能耗效率
2. 关注能效相关的政策变化

data centers AI energy latest

Judge sides with Anthropic to temporarily block the Pentagon's ban

小白 8.4

The Verge AI

法官支持Anthropic，暂时阻止五角大楼的供应链禁令

After Anthropic's weeks-long standoff with the Pentagon, the company won one milestone: A judge granted Anthropic a preliminary injunction in its lawsuit, which sought to reverse its government blacklisting while the judicial process plays out. "The Department of War's records show that it designated Anthropic as a supply chain risk because of its 'hostile manner [...]

为什么你该关心

Anthropic和美国国防部的博弈有了新进展——法官发出初步禁令，暂停了政府的黑名单。这场官司将影响AI公司与政府合作的游戏规则。对AI行业的政商关系有风向标意义。

你现在能做什么

1. 跟踪案件后续发展
2. 评估政府AI政策对你的业务的潜在影响

Anthropic its Pentagon &# Judge

更多（3）

Senators are pushing to find out how much electricity data centers actually use

小白 8.4

美国参议员要求调查数据中心的真实用电量

杨植麟/张鹏/夏立雪/罗福莉/黄超，谈龙虾，谈“Token经济学”

小白 8.4

杨植麟等AI大佬谈Token经济学——AI服务的计价方式正在重塑行业

cporter202/generative-ai-arbitrage

小白 5.4

同一个AI模型在不同平台价格差10倍——一份省钱指南

🚀 创业项目 2 条

对标英伟达EgoScale数据路径，清华系孵化星忆科技拿到首轮融资

进阶 8.4

36氪

> 清华系孵化的星忆科技拿到首轮融资，做具身智能的数据层

文丨任倩 具身数据层的全球竞赛正在迅速升温。NVIDIA Research在2026年发布EgoScale数据与训练框架，在Ego-centric人类操作视频上训练VLA模型，用 20,854小时带动作标注的第一人称人类视频，观察到数据规模和验证损失之间接近对数线性的scaling law。1X收集人类第一视角及家庭行为数据，通过 Sunday项目采集百万小时级家庭场景视频。光轮智能采用仿真合成数据和人类视频数据（EgoSuite）的混合路线，宣称累计交付突破100万小时，估值飙向十亿美金。 几个月内，行业关注点已不再只是“谁采得更多”，而是“谁能把Human-centric /Ego-centric数据真正做成高自由度、高精度、低成本、可训练的资产”。 这背后是一场明确的数据范式迁移。过去一年，全球头部玩家几乎同时把目光转向Human-centric data：不是更大规模的第三人...

为什么你该关心

对标英伟达EgoScale数据路径，做具身智能（Embodied AI）的第一人称视频数据。清华系背景+具身智能赛道+数据层定位，是当前最热的AI创业方向组合。融资成功说明资本对这个赛道的认可。

你现在能做什么

1. 了解EgoScale框架和具身数据的价值
2. 评估具身智能赛道的创业机会

centric 数据 Ego 人类 视频

「龙虾」火热，硬件掘金，这里有10个最新的硬件项目

小白 8.4

36氪

> 10个最新AI硬件创业项目——深圳华强北的「龙虾」热潮

文丨周鑫雨 钟楚笛 编辑丨周鑫雨 若是在春节后来到深圳华强北，你大概率会撞上这样一幕： 在赛格电子世界大厦的二手设备批发档口，短短十几分钟，就有3、4位操着不同口音的客户，询问是否有适配“龙虾”的硬件。 一台部署好“龙虾”的一体机，雅称“虾缸”，售价近期一路从1000元出头，涨到2000元。 华强北，是观察科技行业创业风向的窗口。AI眼镜、录音笔、玩偶……在这里，万物皆可适配“龙虾”。一名科技从业者对我们表示：“出现在华强北，说明做到消费级了。” △3月初深圳的一场千人龙虾硬件聚会。图源：inno100。 龙虾，大名OpenClaw，当下全球最火的开源Agent框架，也是这波硬件热潮的导火索。随着腾讯等大厂的高调入局、各地支持政策的出台，这个能帮用户7*24小时干活的本地Agent，很快被普罗大众所熟知。 当一项青涩的技术，快速从极客的襁褓，被推向大众市场，“不成熟”所带来的落地痛点便...

为什么你该关心

深圳华强北已经在卖AI一体机（「虾缸」），硬件创业者蜂拥而至。这10个项目展示了AI硬件从消费级到工业级的各种形态。对想做AI硬件或关注边缘AI趋势的人来说是必读的市场快照。

你现在能做什么

1. 评估哪些硬件形态与你的业务相关
2. 关注深圳AI硬件供应链动态

龙虾 硬件 适配 周鑫雨 华强北

💡 AI使用技巧 10 条

Ask HN: Is consumer AI boxes a viable idea?

进阶 8.5

HN-AI

HN讨论：消费级AI硬件盒子是不是个好生意?

I suspect at some point LLM in its current form will be deemed good enough for general research and coding tasks. I don't get why we need to continue with a de-facto cloud-based approach. Cloud in my opinion solves operational complexity, which is worth paying a premium for. But it seems it isn't quite all that complex to get an open source model running locally as long as you have the hardware...

为什么你该关心

社区在讨论LLM何时「够好」到可以脱离云端。如果本地推理成本足够低，消费级AI盒子可能成为新品类。对硬件创业者和边缘AI从业者有参考价值。

你现在能做什么

1. 阅读HN讨论串看社区观点
2. 评估本地部署vs云端的成本拐点

get suspect Ask HN consumer

Show HN: I block LLM hallucinations with a cognitive math framework(re!Think it)

进阶 8.5

HN-LLM

用认知数学框架阻止LLM幻觉——一个反直觉的Prompt工程方法

I wrote this prompt intuitively. This is just how I think — formulas, branches, hard conditions. I simply tried to explain to the model how to think, in the same language I use myself. The same language I always used to design database architectures and business logic for clients. What used to be "data flows" and "function nodes" became "input flows" and "deci...

为什么你该关心

作者用数学公式、分支逻辑和硬性约束来教AI「怎么想」，效果出奇地好。这种结构化思维Prompt不是调参，而是改变了AI的推理路径。对频繁遇到幻觉问题的用户很有启发。

你现在能做什么

1. 阅读完整的re!Think协议
2. 在你常用的LLM上测试认知约束Prompt

how think same language used

Show HN: LLM-Gateway — Zero-Trust LLM Gateway

进阶 8.5

HN-LLM

> 单Go二进制的零信任LLM网关，一个YAML配多个后端

I built an OpenAI-compatible LLM gateway that routes requests to OpenAI, Anthropic, Ollama, vLLM, llama-server, SGLang... anything that speaks /v1/chat/completions. Single Go binary, one YAML config file, no infrastructure.It does the things you'd expect from this kind of gateway... semantic routing via a three-layer cascade (keyword heuristics, embedding similarity, LLM classifier) that picks ...

为什么你该关心

一个YAML文件就能把OpenAI、Anthropic、Ollama等各种LLM后端统一管理。零信任架构意味着安全默认开启。对于需要管理多个LLM接入的团队，是运维友好的选择。

你现在能做什么

1. 下载单二进制部署，配置你的LLM后端
2. 测试请求路由和负载均衡效果

LLM ... Gateway OpenAI gateway

更多（7）

Ask HN: What's your desktop setup optimized to work with AI? 小白 8.5

HN讨论：你为AI工作优化了什么样的桌面环境?

Why AI may increase competition but not success rates 小白 8.4

研究发现：AI会增加竞争激烈度，但不会提高整体成功率

Security-by-Design for LLM-Based Code Generation 进阶 8.4

论文：如何让LLM生成的代码天生安全——安全优先设计方法论

Dokis — Runtime RAG provenance enforcement without an LLM call 进阶 8.3

无需LLM调用的运行时RAG来源追溯——确保AI回答有据可查

Skipping 90% of KV dequant work speeds up LLM decode by 22% 高级 8.3

跳过90%的KV反量化计算，LLM解码速度提升22%

Show HN: Isartor — Pure-Rust prompt firewall, deflects 60-95% of LLM traffic 进阶 8.3

纯Rust实现的Prompt防火墙，拦截60-95%的LLM注入攻击

Show HN: LLMBillingKit — measure net margin per LLM call with one line of Python 进阶 8.3

一行代码测量每次LLM调用的净利润——LLMBillingKit

📚 小教程 3 条

marimo-team/modernaicourse

小白 6.5

GitHub

> CMU教授的现代AI入门课配套代码——从ML基础到手搓LLM

A companion to CMU professor Zico Kolter's Intro to Modern AI. Learn the basics of machine learning, then train your own LLM from scratch. (stars: 95) [Python] Discord · Lectures · Course Website _This repo will be updated weekly, as the online version of CMU's Intro to Modern AI progresses. [Join the disc。

为什么你该关心

Zico Kolter是CMU的知名教授，这门课从机器学习基础讲到从零训练LLM。配套代码库让你可以跟着课程动手实践。对想系统学习AI而不是只会调API的人非常有价值。

你现在能做什么

1. clone仓库，跟着课程目录学习
2. 从头训练一个小型LLM理解底层原理

strong modernaicourse href https target

via007/bilibili-rag

进阶 5.4

GitHub

> 把B站收藏夹变成可对话的知识库——语音转写+向量检索+问答

B站收藏夹RAG知识库：收藏不吃灰，B 站收藏夹 → 语音转写 → 向量检索 → 对话问答 (stars: 912) [Python] # 🚀 Bilibili RAG：把收藏夹变成可对话的知识库 把你在 B 站收藏的访谈/演讲/课程，变成可检索、可追溯来源的**个人知识库**。 适合：访谈/演讲/课程、技术视频与学习视频整理、公开课复盘、知识总结、会议/分享回顾、播客内容归档等。 > 亮点：自动拉取内容 → 语音转写 → 向量检索 → 对话问答 --- ## ✨ 功能一览 - ✅ B 站扫码登录，读取收藏夹 - ✅ 音频转文字（ASR），自动兜底处理 - ✅ 语义检索（向量检索） - ✅ 基于 RAG 的对话问答 - ✅ 本地 SQLite + ChromaDB 存储 --- ## 🖼️ 演示与截图 ## B站演示视频： 演示视频 ## ⭐ Star H...

为什么你该关心

收藏了一堆B站视频但从来不看？这个项目把收藏夹自动转写成文字，建立向量检索索引，然后你可以直接对话提问。对中文内容消费者来说是真正的知识管理利器。

你现在能做什么

1. 部署到本地，导入你的B站收藏夹
2. 测试对话检索效果，看是否能替代重复观看

收藏夹 ## 检索 对话 RAG

agenticloops-ai/agentic-ai-engineering

小白 5.4

GitHub

> 从零构建AI Agent的实战教程

Hands-on tutorials for building AI agents from scratch. Learn LLM APIs, prompt engineering, tool calling, and the agent loop through practical examples. (stars: 42) [Python] English | Deutsch | Español | français | [日本語](https://zdoc.app/ja/agenticloops-ai/agenti。

为什么你该关心

不是概念介绍，而是手把手的实战教程。从LLM API调用开始，逐步教你Prompt工程、工具调用、Agent循环的完整链路。对想深入理解Agent底层原理而不只是用框架的开发者来说是最佳学习路径。

你现在能做什么

1. 按教程顺序动手实践
2. 从零实现一个最小可用的Agent

ai agenticloops engineering agentic https